


IMPLEMENTAÇÃO · PYTHON

Classe Board

Como construímos o jogo

A classe Board é o núcleo do projeto — encapsula todo o estado do tabuleiro 7×6 e implementa as mecânicas específicas do PopOut.



Tabuleiro 7 × 6

`drop(col, player)`

Coloca uma peça no topo da coluna escolhida

`pop(col, player)`

Remove a peça da base; a coluna desce toda

`check_win(player)`

Verifica alinhamentos em 4 direções

`is_full() / clone()`

Estado do tabuleiro e cópia profunda para MCTS

`get_legal_moves()`

Lista movimentos válidos (DROP + POP disponíveis)

ARQUITECTURA · FLUXO

Main & Integração ao Terminal

Main.ipynb

- Menu interativo no terminal
- Seleção de modo: H vs H, H vs IA, IA vs IA
- Orquestra o ciclo de turnos
- Exibe o tabuleiro após cada jogada
- Deteta fim de jogo (vitória, empate)

Função de Espera

- Aguarda a resposta do agente IA
- Compatível com qualquer variante MCTS
- Recebe o par (tipo, coluna) do agente
- Valida o movimento antes de executar

Outras Features

- Regra de repetição 3× (empate)
- Vitória simultânea em POP
- Historial de estados do jogo
- Modo Arena: IA vs IA em série
- Log de resultados para análise

INTERFACE → LÓGICA → IA → RESULTADO

ALGORITMO · MONTE CARLO TREE SEARCH

MCTS Vanilla + Heurísticas

1

Selection

Desce a árvore escolhendo o melhor nó via UCT (Upper Confidence Bound)

2

Expansion

Adiciona novos nós-filho ao nó selecionado

3

Simulation

Rollout aleatório até ao fim do jogo (Vanilla) ou guiado por heurísticas

4

Backprop.

Propaga o resultado (vitória/derrota) de volta à raiz

MCTS Vanilla

- Rollout completamente aleatório
- Implementação de referência base
- Sem conhecimento do domínio
- UCT padrão: $C = \sqrt{2}$

MCTS Heurístico

- Deteta vitórias imediatas no rollout
- Bloqueia o adversário proativamente
- Prioriza o centro do tabuleiro
- Heavy playouts com pesagem heurística

FÓRMULA UCT

$$UCT(i) = w_i/n_i + C \cdot \sqrt{\ln(N) / n_i}$$

Heurísticas aumentam drasticamente a qualidade sem perder a essência do MCTS

MCTS · VARIANTES & BENCHMARKING

Multi-Expansion & Resultados da Arena

MCTS Multi-Expansion

Em vez de expandir apenas um filho por iteração, expande vários nós de uma vez — aumentando a diversidade de exploração sem aumentar o número de rollouts.

Vanilla / Heurístico

1 filho / iteração

Multi-Expansion

k filhos / iteração

RESULTADOS DA ARENA (20 jogos cada)

Vanilla Vs Heurístico

Heurístico vs

Vanilla

4-16 · 20-0

Diferença esmagadora

Multi-Exp(5) vs Vanilla

Vanilla vs Multi-

Exp(5)

17-3 · 7-13

Multi superior ao Vanilla

Heurístico vs Multi-Exp(5)

Multi-Exp(5) vs

Heurístico

15-5 · 8-12

Confronto equilibrado

Heurísticas = maior salto de qualidade · Multi-Expansion = alternativa competitiva

CONSTRUÇÃO E PREPARO DE DATASET

Datasets & Produto Final

01 MCTS Self-Play

Heurístico joga contra si mesmo gerando milhares de partidas

02 Filtro de Qualidade

Apenas jogadas vencedoras são guardadas — menos ruído

03 Dataset CSV

Estado do tabuleiro + movimento + resultado como features

04 Treino ID3

Árvore de decisão construída de raiz sobre os dados filtrados

DATASET OUTPUT

Conjunto	Amostras	%
Treino	91.798	80%
Teste	22.950	20%
Total	114.748	100%

DISCRETIZAÇÃO IRIS (pd.qcut — quantis)

Feature	Baixo	Médio	Alto
sepallength	<= 5.40	<= 6.30	<= 7.90
sepalwidth	<= 2.90	<= 3.20	<= 4.40
petallength	<= 2.63	<= 4.90	<= 6.90
petalwidth	<= 0.87	<= 1.60	<= 2.50

APRENDIZAGEM SUPERVISIONADA

ID3 Decision Tree & Iris

Como funciona o ID3

Entropia

Mede a impureza de um conjunto de exemplos

Information Gain

Seleciona o atributo que melhor separa as classes

Construção recursiva

Divide o nó em subárvores até às folhas puras

Resultados no Dataset Iris

Configuração

Treino


Teste

max_depth = none

+95%

+95%

Árvore construída a partir do iris.csv



ID3 · MAX_DEPTH EXPERIMENTS

Treino de Agentes por Profundidade Pop-out

Treinamos múltiplos agentes ID3 com diferentes valores de max_depth para estudar o impacto da profundidade na generalização vs. overfitting.

Sem limite	max_depth = 2	max_depth = 10	max_depth = 18
Treino ~85%	Treino ~28%	Treino ~77%	Treino ~84%
Teste ~69%	Teste ~27%	Teste ~65%	Teste ~69%
 Overfitting severo	 Underfitting	 Em crescimento	 Ponto de Equilíbrio

max_depth = 18 oferece o melhor equilíbrio entre expressividade e generalização no dataset PopOut gerado por self-play

Accuracy ID3 – Dataset PopOut

TOTAL DE AMOSTRAS
114 748
dataset completo


CONJUNTO TREINO
91 798
80% · ajuste do modelo

CONJUNTO TESTE
22 950
20% · avaliação

MELHOR ACCURACY TESTE
68.84%
depth ≥ 18 · estabilizado

MÁX. OVERFITTING
15.85pp
treino vs teste · depth ≥ 18

DISTRIBUIÇÃO · TREINO VS TESTE



MAX DEPTH	ACC. TREINO	ACC. TESTE	OVERFITTING	BARRAS	ESTADO
Depth 2	27.75%	27.40%	0.35pp		Underfitting
Depth 6	47.95%	46.17%	1.78pp		Underfitting
Depth 10	76.53%	64.90%	11.53pp		A crescer
Depth 14	84.41%	68.73%	15.68pp		Overfitting
Depth 18	84.69%	68.84%	15.85pp		Estabilizado
Depth 22 - 30	84.69%	68.84%	15.85pp		Estabilizado
Sem Limite	84.69%	68.84%	15.85pp		Estabilizado

0 modelo estabiliza a partir de Depth 18 — maior profundidade não traz ganho de generalização. Ponto ótimo: Depth 18 com 68.84% de accuracy no teste.

Resultados: ID3 vs Vanilla

ID3 Win Rate

~2-5%

contra MCTS Vanilla (100 jogos)

Vanilla Win Rate

~95-99%

Consistente em todas as profundidades

Empates

~0%

Não registrados nos testes

Profundidade ID3	ID3 Vitórias	Vanilla Vitórias	Empates	Veredicto
Depth 2	2-3	97-98	0	Vanilla domina claramente
Depth 6-10	3-5	95-97	0	Vanilla domina claramente
Depth 14-18	2-5	95-98	0	Vanilla domina claramente
Depth 22-30	2-4	96-99	0	Vanilla domina claramente
Sem Limite	3	97	0	Vanilla domina claramente

O MCTS Vanilla supera consistentemente o ID3 em todas as profundidades — o ID3 não consegue competir com a exploração probabilística do Vanilla

PopOut AI

Heurísticas = diferença real

MCTS Heurístico supera Vanilla de forma esmagadora (20–0)

Multi-Expansion melhor mas não competitivo

Supera Vanilla e compete com Heurístico mas não de forma consistente

ID3 aprende mas não compete

Accuracy de ~69% no teste não se traduz em win rate, o MCTS adapta-se, o ID3 não.

Qualidade > Quantidade

Quantidade de dados não implica na melhoria do modelo, é necessário diversificação

Para ir mais além

Melhorias no Dataset:

- Diversificação das fontes
- Aleatoriedade controlada
- Dataset balanceado por coluna
- Jogos mais longos

Melhorias no ID3:

- Outros critérios de divisão
- Random forest
- ID3 com memória de sequência